

Rzeszów 15.06.2022r.

Szeregi czasowe

Projekt

Złotek Sebastian
Inżynieria i analiza danych

Spis treści

| | |
|--|----|
| 1. Wprowadzenie i omówienie danych..... | 2 |
| 2. Główne cechy analizowanych szeregów | 5 |
| 3. Dekompozycja na podstawie modelu regresji..... | 11 |
| 4. Eliminacja trendu i sezonowości | 16 |
| 5. Uczynienie szeregów stacjonarnymi..... | 17 |
| 6. Wyznaczenie współczynników modelu AR | 23 |
| 7. Wyznaczenie współczynników dla modelu MA(q)..... | 30 |
| 8. Wyznaczenie optymalnych modeli z wykorzystaniem auto.arima..... | 31 |
| 9. Porównanie analizowanych modeli, wybór najlepszego | 32 |
| 10. Prognozowanie | 34 |
| 11. Źródła..... | 38 |

1. Wprowadzenie i omówienie danych

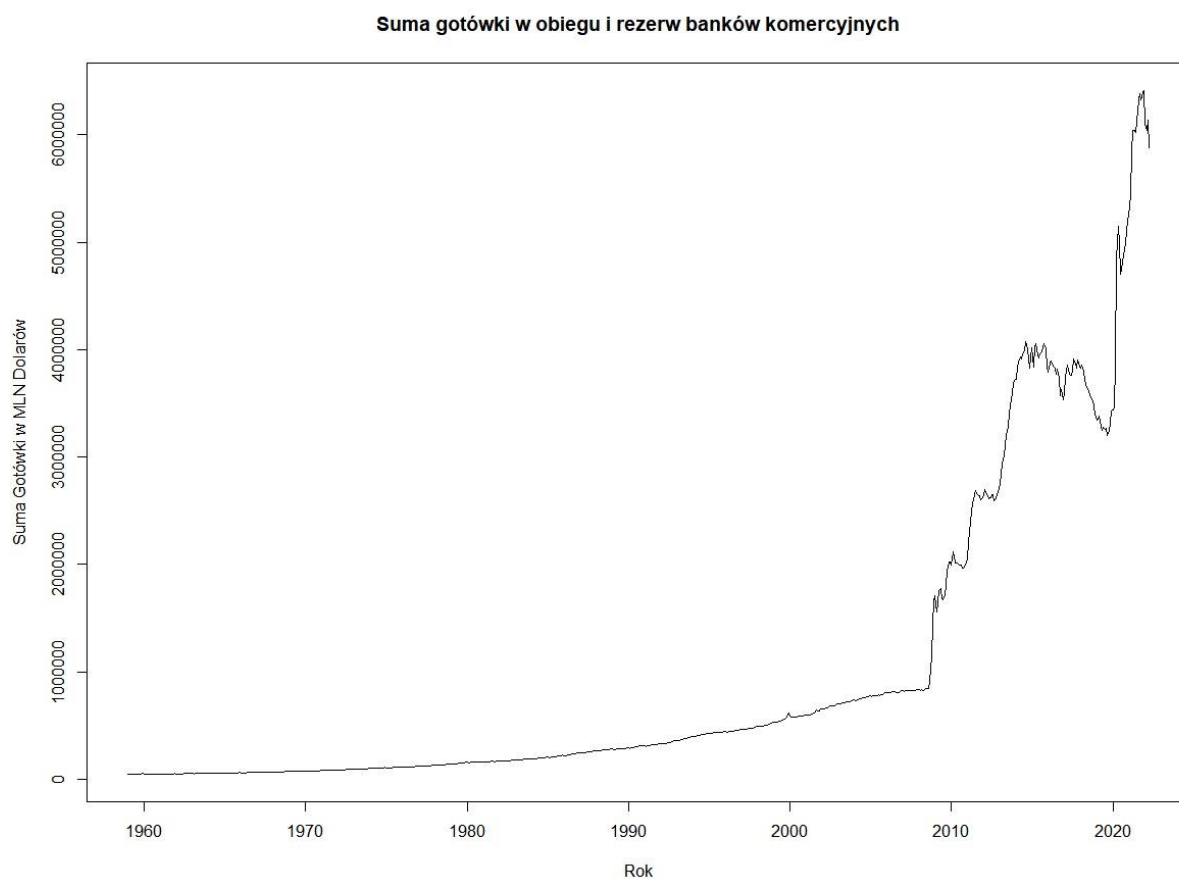
Dane, które zostały użyte w projekcie pochodzą ze strony internetowej fred.stlouisfed.org, jest to strona zajmująca się przechowywaniem i udostępnianiem darmowych danych w postaci szeregów czasowych, dzięki którym użytkownicy mogą pobrać i analizować publiczne szeregi do własnych projektów.

Szeregi, które wykorzystane zostały w projekcie to:

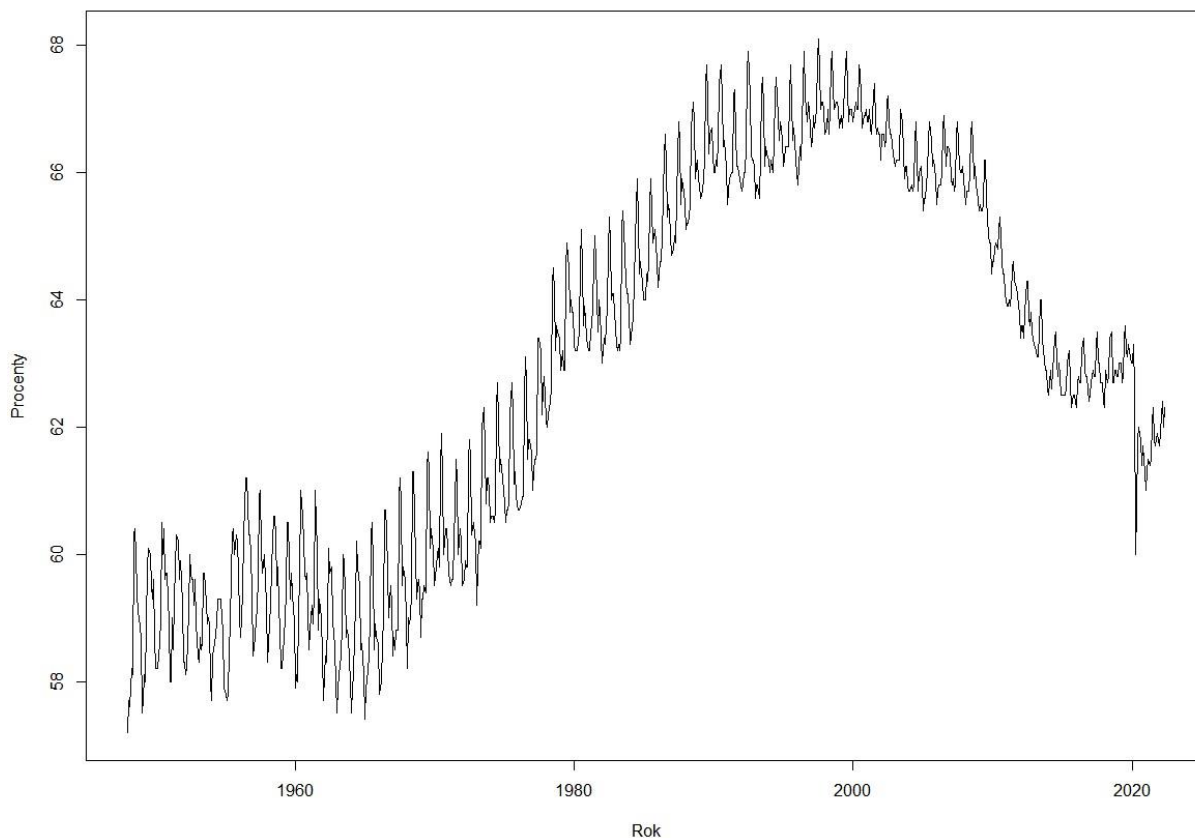
- Labor Force Participation Rate (Współczynnik aktywności zawodowej) – jest to współczynnik określający stosunek osób aktywnych zawodowo do ludności w wieku produkcyjnym. Im wyższa wartość tego wskaźnika, tym większa część ludzi w wieku produkcyjnym pracuje zawodowo. Szereg w tym wypadku jest szeregiem typu sezonowego, obejmującym okres czasu od 1 stycznia 1948 do 1 maja 2022. W tym szeregu nowa wartość występuje w systemie comiesięcznym (tak zwany monthly ts)
- Monetary Base; Total (Suma gotówki w obiegu i rezerw banków komercyjnych na rachunkach w banku centralnym) - czyli łączna ilość pieniądza bezpośrednio wyemitowanego przez bank centralny. Baza monetarna jest czasami określana mianem zasobu pieniądza wielkiej mocy i oznaczana symbolami Bm, M0 bądź H. Ten szereg ma znacząco widoczny trend, obejmuje on dane od 1959-01-01 do 2022-04-01, które również dodawane są w jego przypadku co miesiąc.

Oba szeregi czy też dane są istotne z tego względu, iż powinniśmy się interesować co nastąpi z pieniądzem w przyszłości, co za tym idzie w jakim stopniu ludzie będą aktywni zawodowo, aby na ten pieniądz zarabiać. Ważne są również trafne prognozy dzięki którym będziemy mogli przewidzieć jaki wpływ dane te będą miały na przyszłość całej globalnej ekonomii.

Oba szeregi prezentują się następująco:




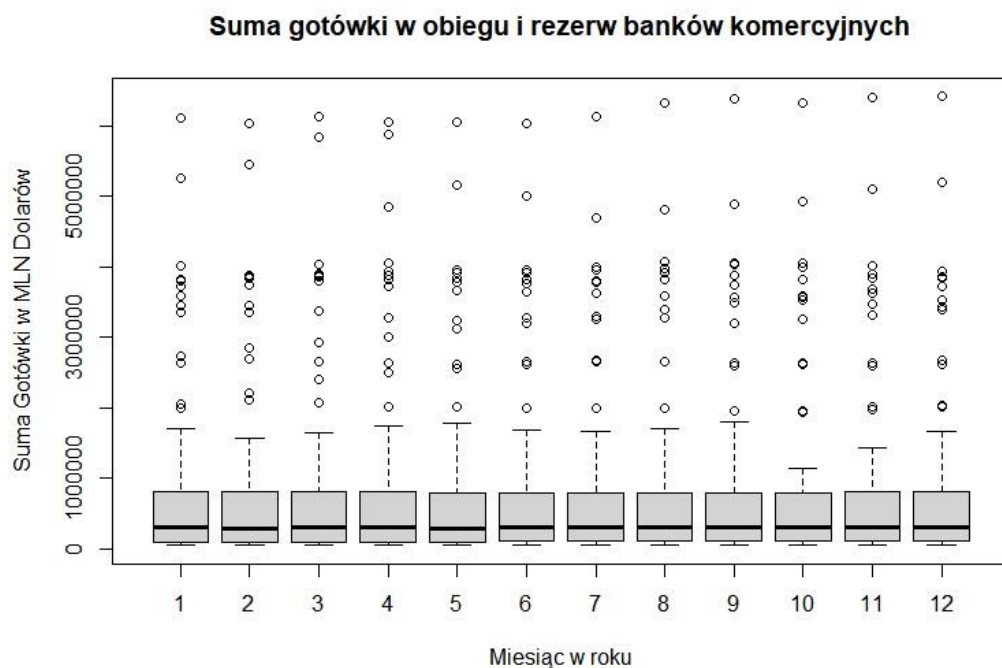
Współczynnik aktywności zawodowej



Są wygenerowane za pomocą funkcji plot, oraz reprezentują wykresy liniowe. Dzięki temu typowi wykresów możemy odczytać dokładnie procenty ludności aktywnie pracującej oraz lata (szereg współczynnika aktywności zawodowej), w pierwszym szeregu jest to natomiast ilość gotówki w milionach dolarów, oraz lata, w których zmieniał się ww. trend, widać gołym okiem, że w okolicy roku 2010 i wyżej ilość banknotów znacząco poszła do góry, co może mieć związek m.in. z rosnącą inflacją.

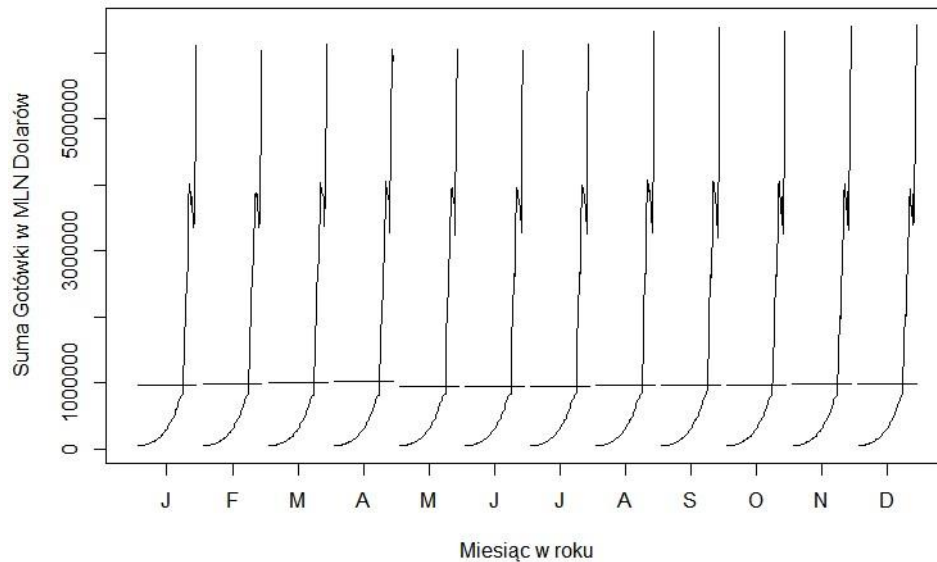
Drugi wykres łatwo pokazuje nam, że od początku lat 80 do ok. roku 2000 procent ludzi będących aktywnie zawodowo rósł, a także co chwile występowała sezonowość w tych procentach.

2. Główne cechy analizowanych szeregów




Na pierwszym wykresie można zobaczyć duże odchylenia w każdym miesiącu, na obu widać także medianę, minimum, maksimum i kwartyle, jest to wykres typu boxplot.

Suma gotówki w obiegu i rezerw banków komercyjnych



Widać trend, gdyż średnie są na tej samej wysokości

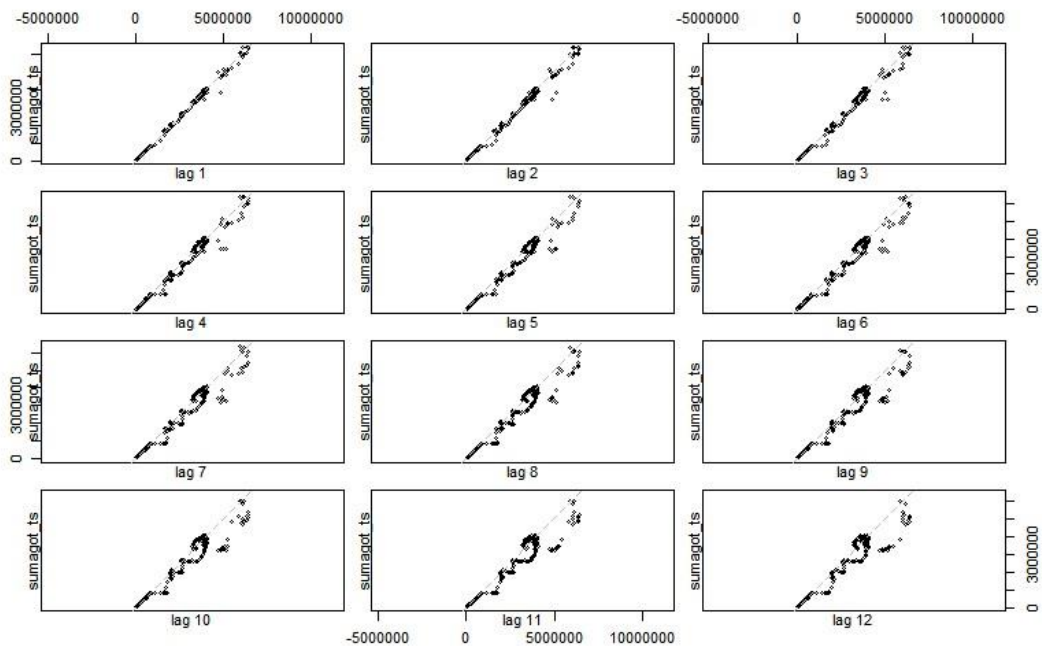
Współczynnik aktywności zawodowej




Wykresy monthplot pokazują wyraźniej miesiąc po miesiącu trend lub sezonowość (widoczną poprzez największą wartość procentową w Lipcu i Sierpniu).

Wykresu typu seasonplot nie zostały użyte, z powodu zbyt dużej ilości lat w szeregach czasowych.

Suma gotówki w obiegu i rezerw banków komercyjnych




Współczynnik aktywności zawodowej




Duża korelacja w pierwszym wykresie lagplot oznacza trend (rozproszone punkty), na drugim wykresie lag12 przedstawia nam najbardziej zwarte punkty (duża korelacja).

Wykresy acf

Suma gotówki w obiegu i rezerw banków komercyjnych




Współczynnik aktywności zawodowej




Acf maleje i wzrasta cyklicznie oznaczając sezonowość w drugim wykresie, oraz równomiernie spada co oznacza trend.

Suma gotówki w obiegu i rezerw banków komercyjnych




Współczynnik aktywności zawodowej

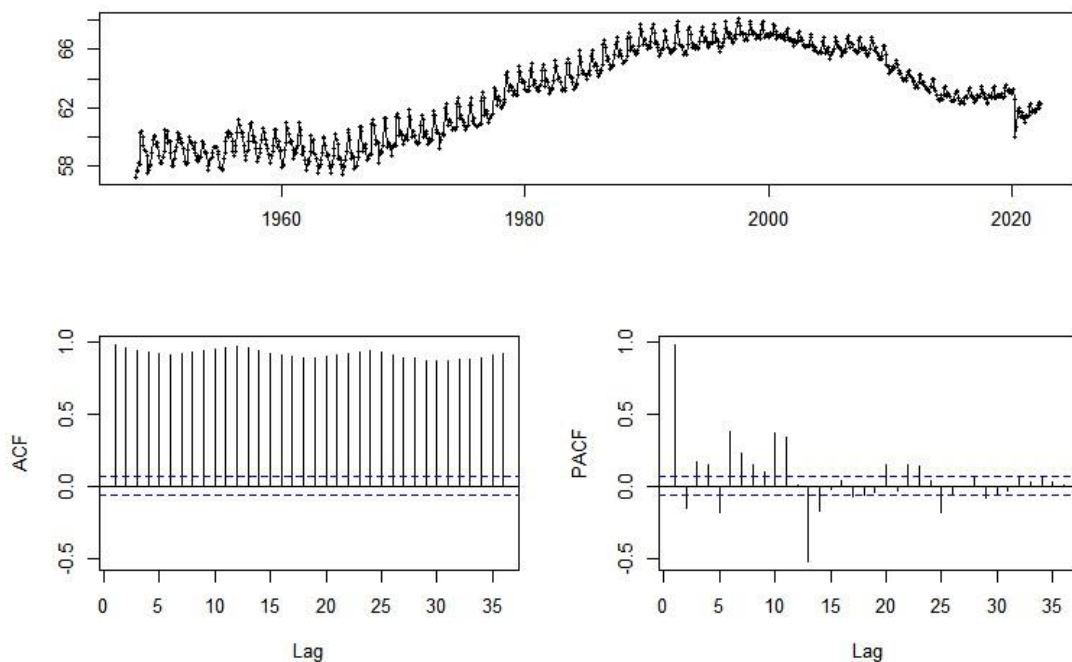


W zależności od tego czy PACF mieści się w przedziale ufności występuje trend.

Suma gotówki w obiegu i rezerw banków komercyjnych




Współczynnik aktywności zawodowej




Wykresy tsdisplay dla porównania wartości.

3. Dekompozycja na podstawie modelu regresji

Decomposition of additive time series







Decomposition of additive time series




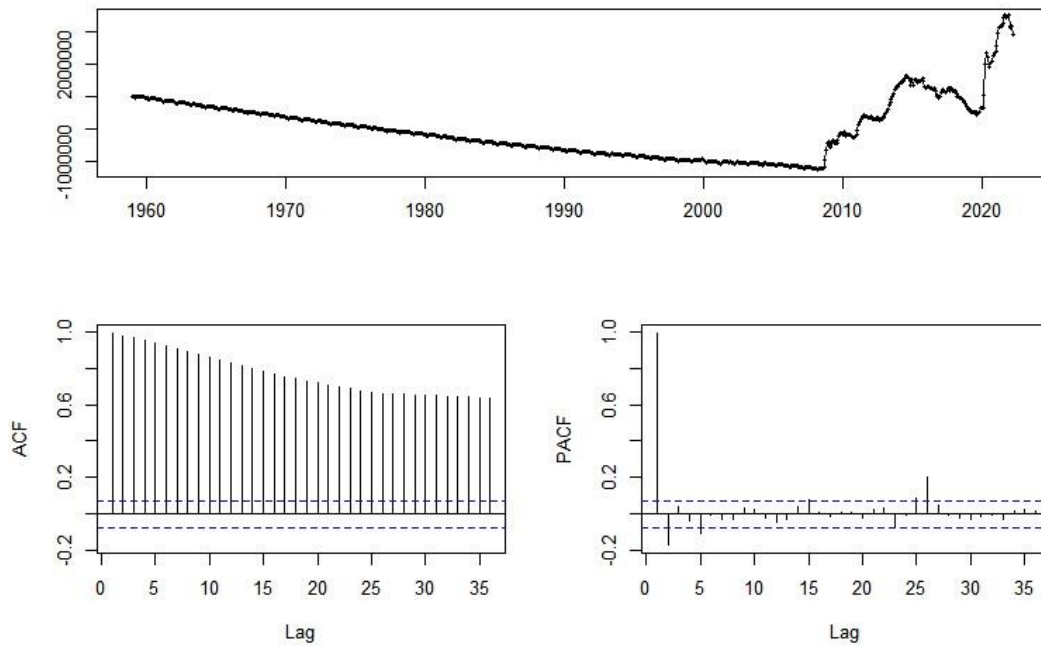
Wykres pierwszy przedstawia dekompozycję sumy gotówki, drugi aktywnych pracujących, jest to dekompozycja addytywna.

Dekompozycja trend liniowy i sezonowość:

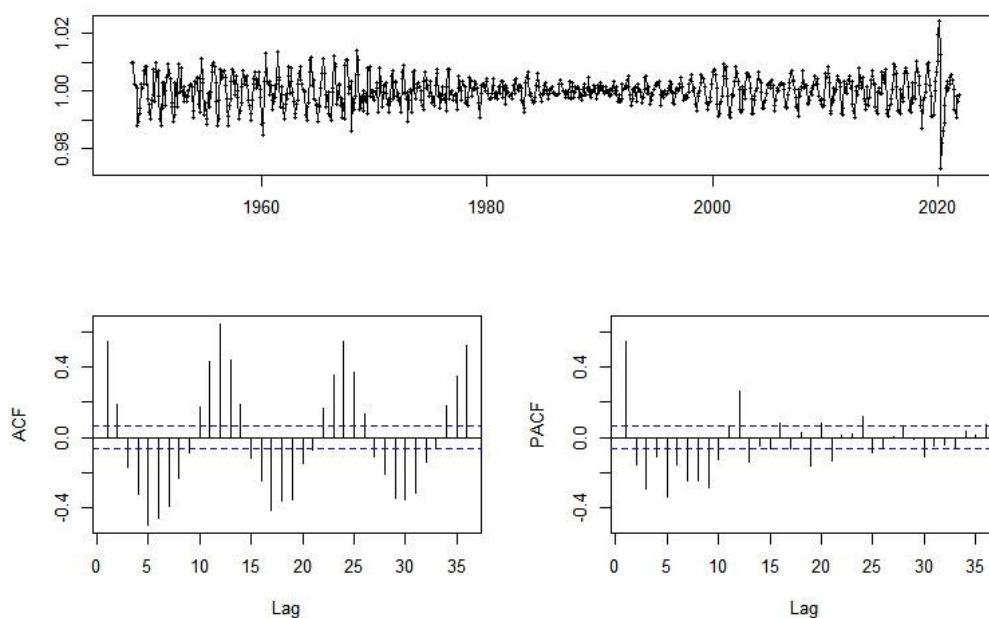





residuals(sumagot_ts4)





zawod_ts5\$random





residuals(zawod_ts4)



Dekompozycja na podstawie modelu regresji w trendzie wielomianowym




4. Eliminacja trendu i sezonowości




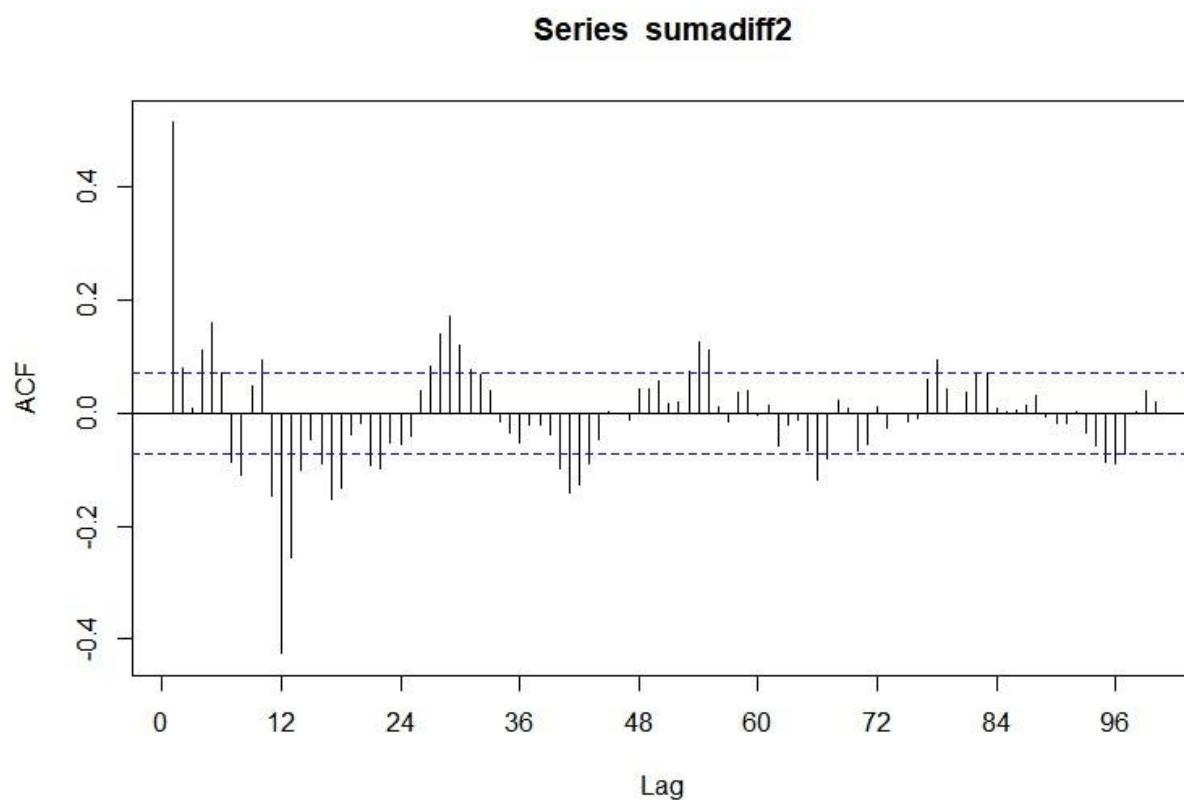

5. Uczynienie szeregów stacjonarnymi

sumagot_ts2



sumadiff






Szereg nie jest realizacją szumu białego




Series sumadiff2






zawod_ts2

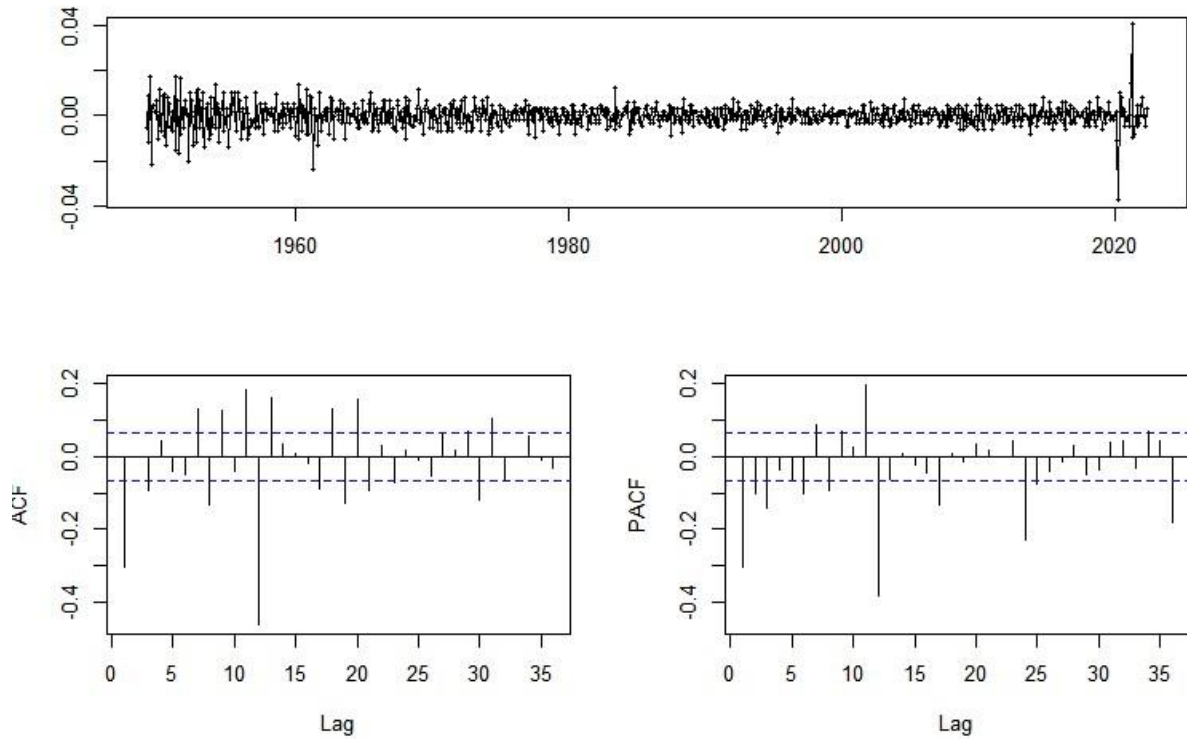


zawoddiff






zawoddiff2




Series zawoddiff2

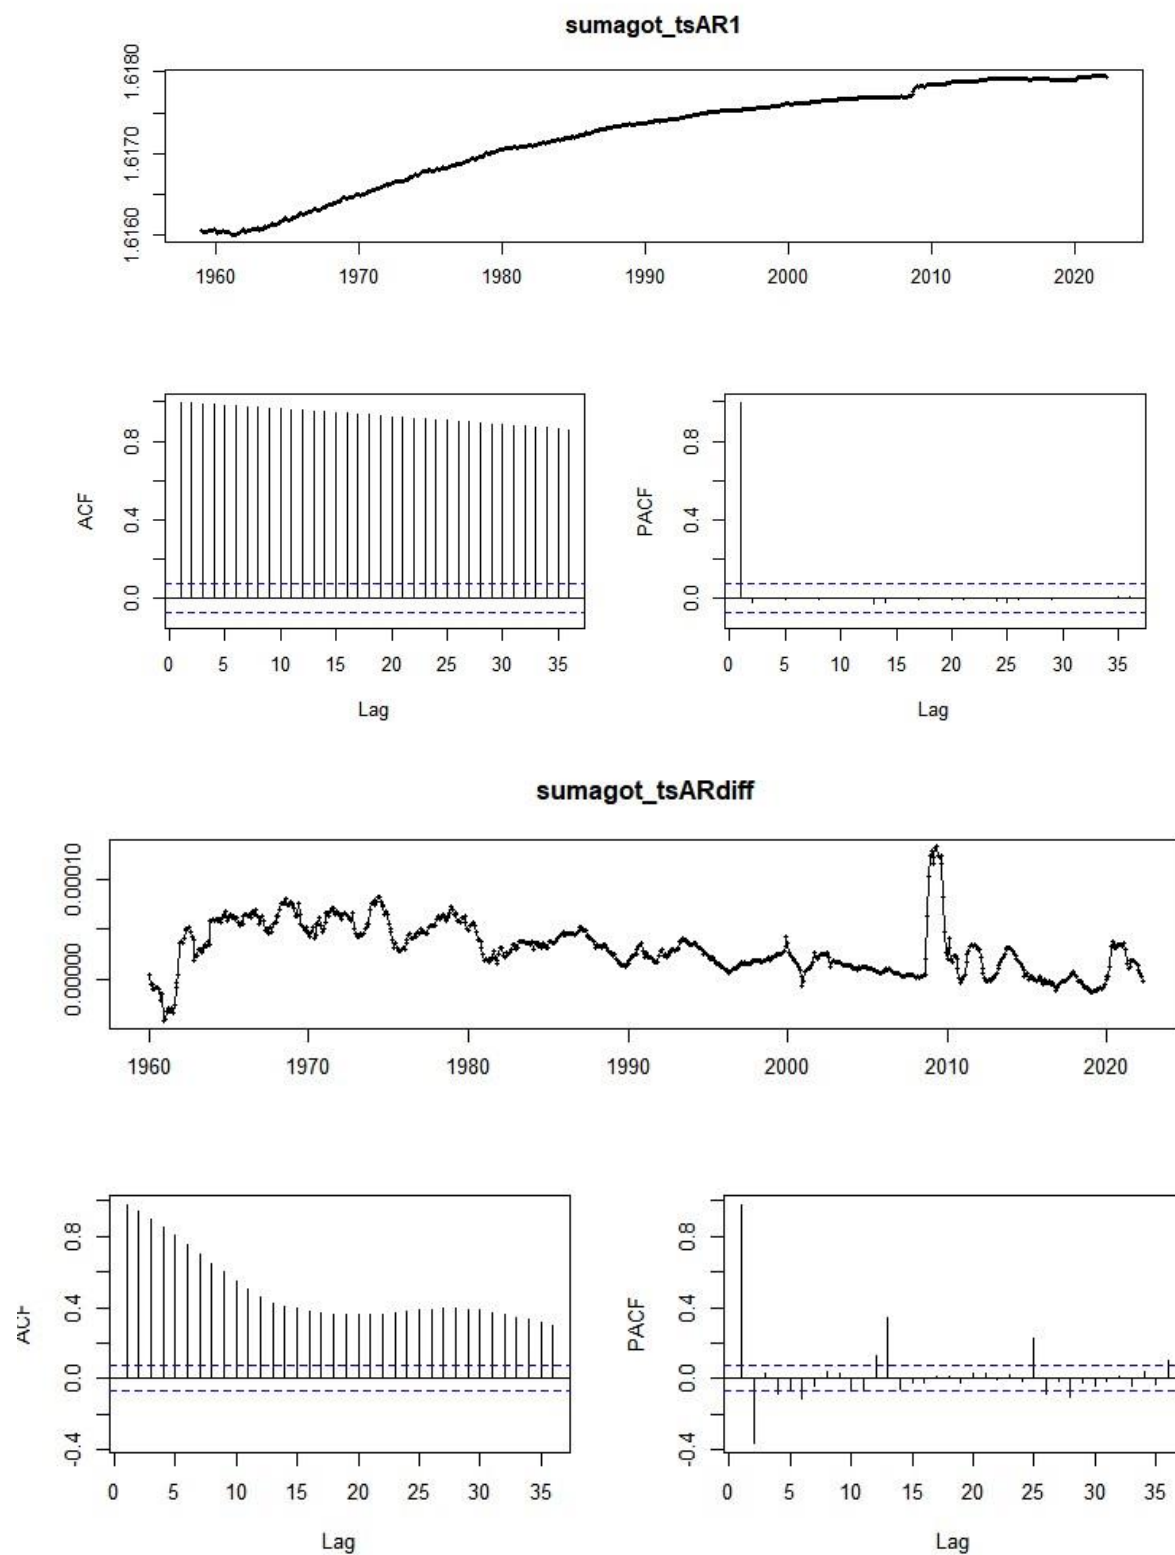




Szereg nie jest realizacją szumu białego

Series zawoddiff2




6. Wyznaczenie współczynników modelu AR







Series sumagot_tsARDiff2



Do wyznaczania współczynnika użyłem metod yule-walker oraz mle, najpierw z określonym p, później z automatycznym.

```
> #wyznaczanie współczynnika modelu autoregresji, p wybrane wcześniej
> ywcheck <- ar(sumagot_tsARDiff2, aic = FALSE, order.max = 96, method = "yule-walker")
> print(ywcheck)

call:
ar(x = sumagot_tsARDiff2, aic = FALSE, order.max = 96, method = "yule-walker")

Coefficients:
 1      2      3      4      5      6      7      8      9     10     11     12     13     14
0.4092 -0.0803 0.0930 -0.0496 0.0713 0.0762 -0.0346 -0.0947 0.0759 0.0444 -0.0349 -0.6507 0.2210 -0.0062
15     16     17     18     19     20     21     22     23     24     25     26     27     28
0.0851 -0.0450 0.0004 0.0444 -0.0111 -0.0805 0.0763 -0.0879 0.1316 -0.5918 0.1949 -0.0081 0.1393 -0.0227
29     30     31     32     33     34     35     36     37     38     39     40     41     42
0.0302 0.0237 0.0001 -0.0068 0.0037 -0.0300 0.0418 -0.4289 0.1265 0.0196 0.0376 0.0332 -0.0134 -0.0224
43     44     45     46     47     48     49     50     51     52     53     54     55     56
0.0425 -0.0629 0.0542 -0.0799 0.0516 -0.2752 0.0784 0.0070 0.0729 0.0117 0.0027 -0.0137 0.0531 -0.0332
57     58     59     60     61     62     63     64     65     66     67     68     69     70
0.0029 -0.0897 0.0696 -0.2167 0.0471 0.0029 0.0596 -0.0143 0.0067 0.0055 -0.0051 0.0886 -0.0545 -0.0384
71     72     73     74     75     76     77     78     79     80     81     82     83     84
0.0479 -0.1530 0.0529 -0.0438 0.0677 -0.0080 0.0257 -0.0017 -0.0134 0.0964 -0.0794 -0.0230 0.0051 -0.0858
85     86     87     88     89     90     91     92     93     94     95     96
0.0035 -0.0076 0.0326 0.0128 -0.0090 0.0440 -0.0478 0.1203 -0.0778 -0.0361 0.0210 -0.0828

order selected 96  sigma^2 estimated as  0.0000000001604
```

```
> mlecheck <- ar(sumagot_tsARDiff2, aic = FALSE, order.max = 30, method = "mle")
> print(mlecheck)

call:
ar(x = sumagot_tsARDiff2, aic = FALSE, order.max = 30, method = "mle")

Coefficients:
 1      2      3      4      5      6      7      8      9     10     11     12     13     14     15
0.3962 -0.0638 0.1049 -0.0993 0.0975 0.0727 -0.0351 -0.1220 0.0638 0.0642 -0.0288 -0.5523 0.1698 0.0271 0.0752
16     17     18     19     20     21     22     23     24     25     26     27     28     29     30
-0.0875 0.0137 0.0587 -0.0203 -0.0815 0.0564 -0.0596 0.1337 -0.3757 0.1289 -0.0260 0.1235 -0.0380 0.0436 0.0097

order selected 30  sigma^2 estimated as  0.0000000001583
```



```
> #wyznaczanie współczynnika modelu autoregresji, automatycznie dobierany rząd  
> ywcheck2 <- ar(sumagot_tsARDiff2, aic = TRUE, order.max = 100, method = "yule-walker")  
> print(ywcheck2)
```

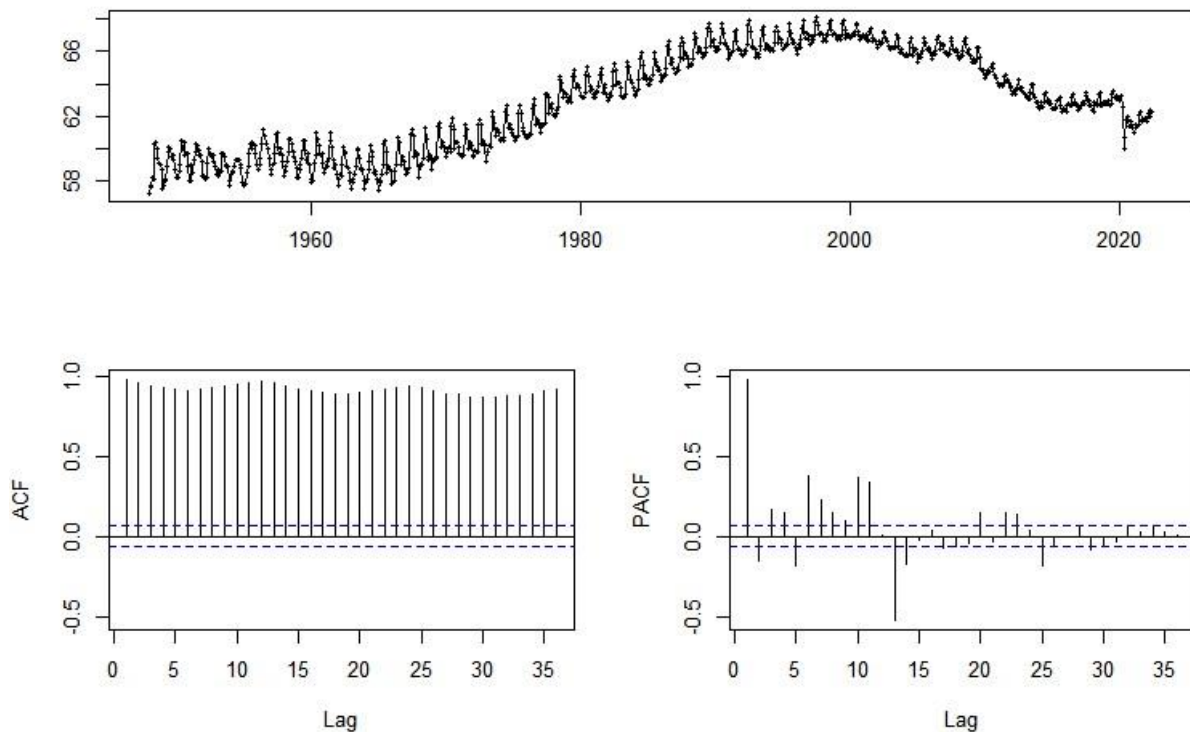
```
Call:  
ar(x = sumagot_tsARDiff2, aic = TRUE, order.max = 100, method = "yule-walker")
```

Coefficients:

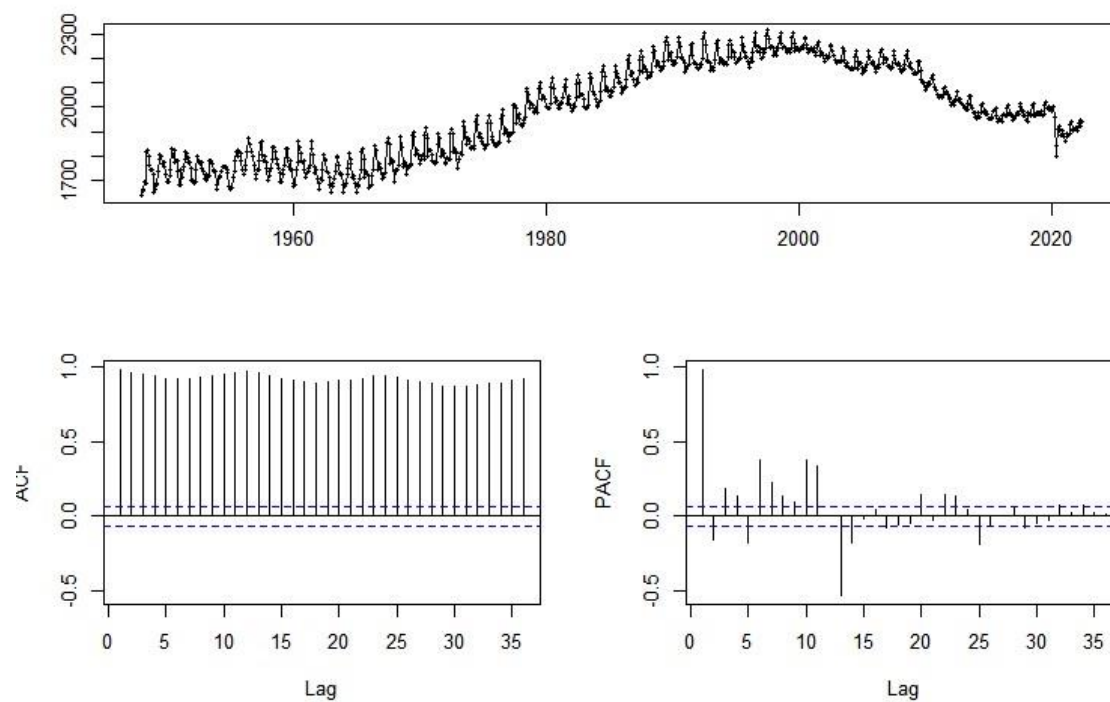
| 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
|---------|---------|---------|---------|---------|---------|---------|---------|---------|--------|---------|---------|---------|--------|--------|
| 0.3919 | -0.0570 | 0.0811 | -0.0670 | 0.0819 | 0.0749 | -0.0367 | -0.0984 | 0.0654 | 0.0674 | -0.0475 | -0.5829 | 0.1885 | 0.0069 | 0.0703 |
| -0.0781 | 0.0151 | 0.0447 | -0.0275 | -0.0625 | 0.0377 | -0.0402 | 0.1104 | -0.4652 | 0.1478 | -0.0055 | 0.1129 | -0.0511 | 0.0369 | 0.0401 |
| -0.0290 | 0.0297 | -0.0469 | 0.0295 | 0.0116 | -0.2440 | 0.0751 | | | | | | | | |

```
Order selected 37  sigma^2 estimated as 0.00000000001613
```


zawod_tsAR



zawod_tsAR1




zawod_tsARdiff






zawod_tsARdiff2




Series zawod_tsARdiff2





Series zawod_tsARDiff2



```
> #wyznaczanie współczynnika modelu autoregresji, p wybrane wcześniej
> ywcheck3 <- ar(zawod_tsARDiff2, aic = FALSE, order.max = 56, method = "yule-walker")
> print(zawod_tsARDiff2)
```

| | Jan | Feb | Mar | Apr | May | Jun | Jul | Aug |
|------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|
| 1949 | | -17.199723479 | 28.916110108 | -40.532534992 | 58.402001623 | -76.801263905 | 11.946298025 | 18.069389141 |
| 1950 | 40.48254142 | -11.516463191 | -23.152880426 | 29.156018093 | -29.076048811 | 36.198755200 | -48.095072441 | 30.075664010 |
| 1951 | -23.372796028 | 0.000000000 | 58.481970904 | -52.718741196 | 23.592711516 | -59.831451347 | 60.131335729 | -30.095656289 |
| 1952 | -0.269896308 | 0.000000000 | -70.118388119 | 35.179147987 | 5.663268178 | 23.812626822 | -47.965122614 | 0.059976854 |
| 1953 | 23.542730734 | -5.833202853 | 35.029205594 | -17.529597036 | -46.915526805 | 11.466482799 | 17.949435448 | -5.953156714 |
| 1954 | 11.966290604 | 46.455703347 | -17.549589365 | 17.569581688 | 11.766367304 | -41.412197036 | 0.000000000 | 11.916309574 |
| 1955 | 11.566444045 | -46.395726347 | -0.069973162 | 34.839278480 | 5.853195176 | 23.792634556 | 35.988836172 | 6.033125852 |
| 1956 | -35.748928873 | -11.876325098 | 11.876325098 | -17.019792900 | 30.375548655 | 7.232662778 | -35.988836172 | -30.425528719 |
| 1957 | -17.349666338 | 35.209136478 | 0.000000000 | -17.769504796 | -18.219331376 | 17.679539827 | 6.093102653 | -30.085660210 |
| 1958 | 6.023129829 | -0.029988482 | -0.029988471 | 11.806351920 | 0.059976892 | -24.192480177 | -6.093102653 | 36.348697113 |
| 1959 | 17.769504842 | -17.529597044 | 11.596432589 | -0.059976930 | -12.016271070 | 17.779501021 | 0.000000000 | -17.979423892 |
| 1960 | -29.186006532 | 11.596432550 | -35.019209428 | 46.735595914 | 5.993141318 | 18.469234669 | -24.312433824 | 11.956294178 |
| 1961 | 29.006075672 | 5.993141455 | 29.395925891 | -82.094674746 | -0.099961512 | 11.896317279 | -6.053118124 | 0.039984549 |
| 1962 | -5.353387071 | 5.563306421 | -6.123091464 | 11.876325028 | 11.476478768 | -30.805382321 | 6.412979065 | 30.085660135 |
| 1963 | 11.756371236 | -0.079969360 | -5.873187517 | 23.302822921 | -11.726382659 | -0.109957628 | 17.959431590 | -35.788913300 |
| 1964 | 0.000000000 | 0.000000000 | 0.000000000 | 17.559585527 | 0.149942354 | -5.693256872 | -17.999416159 | 11.926305715 |
| 1965 | -11.546451694 | 5.743237335 | -5.803214359 | -11.756371168 | 5.743237452 | 17.839477789 | 36.068805292 | -24.202476427 |
| 1966 | -6.133087880 | -23.032926379 | 0.000000000 | 11.696394191 | -11.696394191 | 24.192480222 | -12.076247840 | 23.932580636 |
| 1967 | -0.479815720 | 11.776363504 | -17.509604703 | -17.379654612 | -23.512742286 | 23.932580370 | 18.309296345 | -6.233048497 |
| 1968 | -35.409059504 | 29.305960494 | 5.823206705 | -11.696394199 | 23.672680757 | -11.016656832 | -18.309296345 | -18.259315685 |
| 1969 | 41.112312348 | -11.476478729 | 5.893179806 | 5.983145175 | -29.615841322 | 6.133087162 | 12.296162695 | 24.222468695 |
| 1970 | 5.453349251 | -17.499608712 | 11.976286443 | -5.873187547 | -12.036263312 | -23.832619145 | 18.519214953 | -24.642305989 |
| 1971 | 11.916309574 | -23.852611440 | -17.929443156 | -0.049980721 | 17.979423877 | -24.712279200 | 11.976286704 | 24.672294362 |
| 1972 | -17.929443149 | 11.916309574 | 23.872603729 | -11.936301863 | 0.000000000 | 30.855362486 | -24.302437761 | -0.089965107 |
| 1973 | -17.799493247 | 29.735795113 | 6.073110436 | 5.983145150 | -6.013133575 | 12.885934374 | 0.149941771 | -24.862220612 |
| 1974 | 29.315957331 | -29.635833703 | -23.992557452 | -6.053118124 | 18.129365957 | -17.589575149 | 6.353001699 | 5.923168785 |



```
> mlecheck2 <- ar(zawod_tsARDiff2, aic = FALSE, order.max = 30, method = "mle")
> print(mlecheck2)

Call:
ar(x = zawod_tsARDiff2, aic = FALSE, order.max = 30, method = "mle")

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12     13     14
-0.2934 -0.1731 -0.1218 -0.1081 -0.1091 -0.0680  0.0100 -0.0886  0.0140 -0.0087  0.0434 -0.5543 -0.1157 -0.0848
      15      16      17      18      19      20      21      22      23      24      25      26      27      28
-0.0511 -0.1081 -0.1648 -0.0268 -0.0274 -0.0016 -0.0379 -0.0594 -0.0533 -0.3325 -0.1294 -0.0800 -0.0133  0.0329
      29      30
-0.0710 -0.0488

Order selected 30  sigma^2 estimated as 215.3
```

```
> #Wyznaczenie współczynnika modelu autoregresji, automatycznie dobierany rzęd
> ywcheck4 <- ar(zawod_tsARDiff2, aic = TRUE, order.max = 100, method = "yule-walker")
> print(zawod_tsARDiff2)

      Jan      Feb      Mar      Apr      May      Jun      Jul      Aug
1949  40.482554142 -11.516463191 -23.152880426 29.156018093 -29.076048811 36.198755200 -48.095072441 30.075664010
1951 -23.372796028  0.000000000 58.481970904 -52.718741196 23.592711516 -59.831451347 60.131335729 -30.095656289
1952  -0.269896308  0.000000000 -70.118388119 35.179147987  5.663268178 23.812626822 -47.965122614  0.059976854
1953 23.542730734  -5.833202853 35.029205594 -17.529597036 -46.915526805 11.466482799 17.949435448  -5.953156714
1954 11.966290604 46.455703347 -17.549589365 17.569581688 11.766367304 -41.412197036  0.000000000 11.916309574
1955 11.566444045 -46.395726347 -0.069973162 34.839278400  5.853195176 23.792634556 35.988836172  6.033125852
1956 -35.748928873 -11.876325098 11.876325098 -17.019792900 30.375548655  7.232662778 -35.988836172 -30.425528719
1957 -17.349666338 35.209136478  0.000000000 -17.769504796 -18.219331376 17.679539827  6.093102653 -30.085660210
1958  6.023129829 -0.029988482 -0.029988471 11.806351920  0.059976892 -24.192480177 -6.093102653 36.348697113
1959 17.769504842 -17.529597044 11.596432589 -0.059976930 -12.016271070 17.779501021  0.000000000 -17.979423892
1960 -29.186006532 11.596432550 -35.019209428 46.735595914  5.993141318 18.469234669 -24.312433824 11.956294178
1961 29.006075672  5.993141455 29.395925891 -82.094674746 -0.099961512 11.896317279 -6.053118124  0.039984549
1962  -5.353387071  5.563306421 -6.123091464 11.876325028 11.476478768 -30.805382321  6.412979065 30.085660135
1963 11.756371236 -0.079969360 -5.873187517 23.302822921 -11.726382659 -0.109957628 17.959431590 -35.788913300
1964  0.000000000  0.000000000  0.000000000 17.559585527  0.149942354 -5.693256872 -17.999416159 11.926305715
1965 -11.546451694  5.743237335 -5.803214359 -11.756371168  5.743237452 17.839477789 36.068805292 -24.202476427
1966 -6.133087880 -23.032926379  0.000000000 11.696394191 -11.696394191 24.192480222 -12.076247840 23.932580636
1967 -0.479815720 11.776363504 -17.509604703 -17.379654612 -23.512742286 23.932580370 18.309296345 -6.233048497
1968 -35.409059504 29.305960494  5.823206705 -11.696394199 23.672680757 -11.016656832 -18.309296345 -18.259315685
1969 41.112312348 11.476478729  5.893179806  5.983145175 -29.615841322  6.133087162 12.296162695 24.222468695
1970  5.453349251 -17.499608712 11.976286443 -5.873187547 -12.036263312 -23.832619145 18.519214953 -24.642305989
1971 11.916309574 -23.852611440 -17.929443156 -0.049980721 17.979423877 -24.712279200 11.976286704 24.672294362
1972 -17.929443149 11.916309574 23.872603729 -11.936301863  0.000000000 30.855362486 -24.302437761 -0.089965107
1973 -17.799493247 29.735795113  6.073110436  5.983145150 -6.013133575 12.885934374  0.149941771 -24.862220612
1974 29.315957331 -29.635833703 -23.992557452 -6.053118124 18.129365957 -17.589575149  6.353001699  5.923168785
```

7. Wyznaczenie współczynników dla modelu MA(q)

```
> sumagot_arima <- Arima(sumagot_tsARDiff2, order = c(5,0,0))
> summary(sumagot_arima)
Series: sumagot_tsARDiff2
ARIMA(5,0,0) with non-zero mean

Coefficients:
      ar1      ar2      ar3      ar4      ar5      mean
      0.3946 -0.0907  0.0590  0.0069  0.0888  0.0000
s.e.      0.1622  0.1206  0.2054  0.1885  0.2630  0.0006

sigma^2 = 0.0000000000229: log likelihood = 8093.58
AIC=-16173.16  AICC=-16173.01  BIC=-16140.85

Training set error measures:
      ME      RMSE      MAE MPE MAPE      MASE      ACF1
Training set 0.000000008709539 0.000004766656 0.000002872741 Inf Inf 0.5699762 -0.00183682
```

```
> zawod_arima <- Arima(zawod_tsARDiff2, order = c(30,0,0))
> summary(zawod_arima)
Series: zawod_tsARDiff2
ARIMA(30,0,0) with non-zero mean

Coefficients:
      ar1      ar2      ar3      ar4      ar5      ar6      ar7      ar8      ar9      ar10      ar11      ar12      ar13      ar14
-0.2948 -0.1724 -0.1214 -0.1093 -0.1086 -0.0711  0.0107 -0.0895  0.0144 -0.0076  0.0425 -0.5531 -0.1169 -0.0849
s.e.      0.0337  0.0352  0.0358  0.0361  0.0366  0.0369  0.0355  0.0354  0.0356  0.0355  0.0355  0.0356  0.0403  0.0411
      ar15      ar16      ar17      ar18      ar19      ar20      ar21      ar22      ar23      ar24      ar25      ar26      ar27      ar28
-0.0503 -0.1103 -0.1624 -0.0321 -0.0260 -0.0032 -0.0366 -0.0600 -0.0542 -0.3317 -0.1305 -0.0791 -0.012  0.0280
s.e.      0.0416  0.0416  0.0418  0.0421  0.0386  0.0385  0.0385  0.0385  0.0384  0.0384  0.0400  0.0407  0.041  0.0408
      ar29      ar30      mean
-0.0662 -0.0581 -0.0179
s.e.      0.0404  0.0387  0.1302

sigma^2 = 223.2: log likelihood = -3615.62
AIC=7295.24  AICC=7297.73  BIC=7448.2

Training set error measures:
      ME      RMSE      MAE MPE MAPE      MASE      ACF1
Training set -0.01006329 14.67446 10.58702 NaN Inf 0.4705091 0.0007021577
```

8. Wyznaczenie optymalnych modeli z wykorzystaniem auto.arima

```
> (sumagot_aicc <- auto.arima(sumagot_ts2, ic = c("aicc")))
Series: sumagot_ts2
ARIMA(0,2,1)(0,0,2)[12]

Coefficients:
      ma1      sma1      sma2
    -0.8451  0.0789  -0.1033
s.e.   0.0389  0.0386  0.0417

sigma^2 = 3376310048: log likelihood = -9390.12
AIC=18788.25 AICC=18788.3 BIC=18806.77
> (sumagot_aic <- auto.arima(sumagot_ts2, ic = c("aic")))
Series: sumagot_ts2
ARIMA(0,2,1)(0,0,2)[12]

Coefficients:
      ma1      sma1      sma2
    -0.8451  0.0789  -0.1033
s.e.   0.0389  0.0386  0.0417

sigma^2 = 3376310048: log likelihood = -9390.12
AIC=18788.25 AICC=18788.3 BIC=18806.77
> (sumagot_bic <- auto.arima(sumagot_ts2, ic = c("bic")))
Series: sumagot_ts2
ARIMA(0,2,1)

Coefficients:
      ma1
    -0.8237
s.e.   0.0356

sigma^2 = 3423121542: log likelihood = -9396.12
AIC=18796.24 AICC=18796.26 BIC=18805.5
```

```
> (zawod_aicc <- auto.arima(zawod_ts2, ic = c("aicc")))
Series: zawod_ts2
ARIMA(2,1,2)(1,1,2)[12]

Coefficients:
      ar1      ar2      ma1      ma2      sar1      sma1      sma2
    -0.0379  0.3364  -0.2643  -0.4068  -0.0889  -0.6185  -0.1026
s.e.   0.2263  0.1034  0.2269  0.1585  0.5109  0.5082  0.3713

sigma^2 = 0.05588: log likelihood = 19.64
AIC=-23.28 AICC=-23.11 BIC=14.96
> (zawod_aic <- auto.arima(zawod_ts2, ic = c("aic")))
Series: zawod_ts2
ARIMA(2,1,2)(1,1,2)[12]

Coefficients:
      ar1      ar2      ma1      ma2      sar1      sma1      sma2
    -0.0379  0.3364  -0.2643  -0.4068  -0.0889  -0.6185  -0.1026
s.e.   0.2263  0.1034  0.2269  0.1585  0.5109  0.5082  0.3713

sigma^2 = 0.05588: log likelihood = 19.64
AIC=-23.28 AICC=-23.11 BIC=14.96
> (zawod_bic <- auto.arima(zawod_ts2, ic = c("bic")))
Series: zawod_ts2
ARIMA(1,1,1)(1,1,2)[12]

Coefficients:
      ar1      ma1      sar1      sma1      sma2
    0.4473  -0.7290  -0.1422  -0.570  -0.1338
s.e.   0.0767  0.0595  0.6538  0.649  0.4728

sigma^2 = 0.05608: log likelihood = 17.14
AIC=-22.27 AICC=-22.18 BIC=6.41
```




9. Porównanie analizowanych modeli, wybór najlepszego

```
> summary(sumagot_aicc)
Series: sumagot_ts2
ARIMA(0,2,1)(0,0,2)[12]

Coefficients:
      ma1      sma1      sma2
    -0.8451  0.0789 -0.1033
s.e.    0.0389  0.0386  0.0417

sigma^2 = 3376310048: log likelihood = -9390.12
AIC=18788.25  AICC=18788.3  BIC=18806.77

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -110.3994 57914.57 17914.81 0.04804531 1.090715 0.1424069 0.3325359
> summary(sumagot_aic)
Series: sumagot_ts2
ARIMA(0,2,1)(0,0,2)[12]

Coefficients:
      ma1      sma1      sma2
    -0.8451  0.0789 -0.1033
s.e.    0.0389  0.0386  0.0417

sigma^2 = 3376310048: log likelihood = -9390.12
AIC=18788.25  AICC=18788.3  BIC=18806.77

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -110.3994 57914.57 17914.81 0.04804531 1.090715 0.1424069 0.3325359
> summary(sumagot_bic)
Series: sumagot_ts2
ARIMA(0,2,1)

Coefficients:
      ma1
    -0.8237
s.e.    0.0356

sigma^2 = 3423121542: log likelihood = -9396.12
AIC=18796.24  AICC=18796.26  BIC=18805.5

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -270.0425 58391.86 17735.33 0.04141038 1.080444 0.1409802 0.3206892
```



```
> summary(zawod_aicc)
Series: zawod_ts2
ARIMA(2,1,2)(1,1,2)[12]

Coefficients:
      ar1      ar2      ma1      ma2      sar1      sma1      sma2
-0.0379  0.3364 -0.2643 -0.4068 -0.0889 -0.6185 -0.1026
s.e.    0.2263  0.1034  0.2269  0.1585  0.5109  0.5082  0.3713

sigma^2 = 0.05588: log likelihood = 19.64
AIC=-23.28  AICC=-23.11  BIC=14.96

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.002851879  0.2337278  0.1649793 -0.004661203  0.2661513  0.4688606  0.003365935
> summary(zawod_aic)
Series: zawod_ts2
ARIMA(2,1,2)(1,1,2)[12]

Coefficients:
      ar1      ar2      ma1      ma2      sar1      sma1      sma2
-0.0379  0.3364 -0.2643 -0.4068 -0.0889 -0.6185 -0.1026
s.e.    0.2263  0.1034  0.2269  0.1585  0.5109  0.5082  0.3713

sigma^2 = 0.05588: log likelihood = 19.64
AIC=-23.28  AICC=-23.11  BIC=14.96

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.002851879  0.2337278  0.1649793 -0.004661203  0.2661513  0.4688606  0.003365935
> summary(zawod_bic)
Series: zawod_ts2
ARIMA(1,1,1)(1,1,2)[12]


Coefficients:
      ar1      ma1      sar1      sma1      sma2
0.4473 -0.7290 -0.1422 -0.570 -0.1338
s.e.   0.0767  0.0595  0.6538  0.649  0.4728

sigma^2 = 0.05608: log likelihood = 17.14
AIC=-22.27  AICC=-22.18  BIC=6.41


Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.002689203  0.2344056  0.1654648 -0.004416322  0.2669383  0.4702404 -0.0202978
> |
```

10. Prognozowanie


Prognoza sumy gotówki na podstawie średniej




Prognoza Wsp. Akt. Zawodowej na podstawie średniej




Prognoza sumy gotówki na podstawie metody naiwnej




Prognoza sumy gotówki na podstawie metody naiwnej sezonowej




Prognoza Wsp. Akt. Zawodowej na podstawie metody naiwnej




Prognoza Wsp. Akt. Zawodowej na podstawie metody naiwnej sezonowej



Proгноza sumy gotówki na podstawie metody uwzgl. dryf



Proгноza Wsp. Akt. Zawodowej na podstawie metody uwzgl. dryf



Metoda naiwna - metoda ta stosowana jest przy stałym poziomie zjawiska i niewielkich wahaniach przypadkowych i przy założeniu, że nie wystąpią istotne zmiany najważniejszych czynników.

```
> #dobór najlepszej metody prognozy
> (accuracy(sumagot_forecast))
Training set 0.000000000006218072 1448351 1084445 -489.424 518.7374 8.620378 0.9913201
> (accuracy(sumagot_naive))
Training set 7687.352 60177.23 19100.53 0.6031654 1.188467 0.1518323 0.4449784
> (accuracy(sumagot_snaive))
Training set 98413.24 333802.8 125800.1 6.934254 7.81391 1 0.9694497
> (accuracy(sumagot_dryf))
Training set -0.00000000001793078 59684.2 22314.73 -4.008009 4.748646 0.1773824 0.4449784
> (accuracy(zawod_forecast))
Training set -0.00000000000003125661 3.012733 2.644797 -0.2315191 4.229077 7.516342 0.9837407
> (accuracy(zawod_naive))
Training set 0.005717489 0.509297 0.3651345 0.00617573 0.5861583 1.037689 0.1785045
> (accuracy(zawod_snaive))
Training set 0.04358683 0.4769131 0.3518729 0.06940743 0.5638934 1 0.7916827
> (accuracy(zawod_dryf))
Training set -0.000000000000002461366 0.5092649 0.3658268 -0.002941622 0.587279 1.039656 0.1785045
```

Jak widzimy z analizy najlepszym prognozowaniem dla szeregu sumy gotówki w obiegu jak i aktywności zawodowej jest metoda średniej.

11. Źródła

- <https://fred.stlouisfed.org/series/BOGMBASE>
- <https://fred.stlouisfed.org/series/LNU01300000>
- https://pl.wikipedia.org/wiki/Baza_monetarna
- https://pl.wikipedia.org/wiki/Wsp%C3%B3%C5%82czynnik_aktywno%C5%9Bci_zawodowej